


Introduction to Spark

빅데이터


■ 빅데이터의 3대 요소

- 크기 (Volume), 속도 (Velocity), 다양성 (Variety)




하둡 (Hadoop)

- 빅데이터를 분산 처리할 수 있는 자바 기반의 오픈소스 프레임워크
- 분산 파일 시스템인 HDFS(Hadoop Distributed Files System)에 데이터를 저장하고 분산 처리 시스템인 맵리듀스를 이용해 데이터를 처리
- 2005년에 더그 커팅 (Doug Cutting)이 구글이 논문으로 발표한 GFS(Google File System)와 MapReduce를 구현한 결과물



하둡 에코시스템



하둡의 단점

- 대부분의 연산 작업을 파일시스템 기반으로 처리 → 상대적으로 낮은 성능
- 복잡한 데이터 분석 요구사항을 맵과 리듀스 패턴만으로 해결하기 어려움
- 자바 언어 기반으로 파이썬, R 등 다른 분석용 도구와 연동이 어려움
- SQL on Hadoop 계열의 도구와 같이 맵리듀스를 편리하게 구현할 수 있는 도구들이 있지만 데이터 분석 요구사항을 충분히 반영하는데 한계가 있음

스파크 (Spark)

- 하둡 기반 맵리듀스의 단점을 보완하기 위해 개발된 분산 데이터 처리 환경
- 메모리를 이용한 데이터 저장 방식을 제공함으로써 머신러닝 등 반복적인 데이터 처리가 필요한 분야에서 높은 성능 구현
- 최적화 과정을 통해 효율적인 데이터 처리 및 성능 향상 가능
- 자연스럽고 강력한 다수의 데이터 처리 함수 제공 → 프로그램의 복잡도를 현저하게 낮춤
- 자바, 스칼라, 파이썬, R을 사용해서 스파크 애플리케이션 개발 가능
- Spark SQL, MLlib 등 다양한 데이터 처리 분야에 특화된 라이브러리 제공

스파크 구성 요소

Spark SQL +
DataFrames

Streaming

MLlib
Machine Learning

GraphX
Graph
Computation

Spark Core API

R

SQL


Python

Scala

Java


실행 아키텍처

- 모든 스파크 애플리케이션은 여러 개의 잡을 관리하는 드라이버 프로세스를 마스터 노드에서 실행
- 드라이버 프로세스는 태스크의 수와 구성 결정 → 태스크 프로세스는 실행 노드에서 관리



비순환 방향성 그래프 (DAG)

- 스파크 잡에서 객체 의존성은 비순환 방향성 그래프 형태로 구성
- 이 그래프를 기반으로 스케줄링 및 실행 최적화 수행



스파크 데이터 모델

- RDD (Resilient Distributed Dataset)


- 변경 불가능(Immutable)한 자바 가상 머신 객체 집합
- 스파크 내부에 존재하는 분산 데이터에 대한 모델
- 다수의 서버에 분산 방식으로 저장된 데이터 요소들의 집합
- 병렬 처리 및 장애 복구 가능

- DataFrame(after 1.3), DataSet(after 1.6)

- Column들로 구성된 Schema를 사용하는 데이터 모델
- 관계형 데이터베이스의 테이블과 유사한 방식의 데이터 처리 모델 제공
- 향상된 최적화 도구 사용
- 스파크 2.0부터 DataFrame 클래스는 DataSet 클래스로 통합
 - » R, 파이썬은 DataFrame 형식 사용
 - » 자바는 DataSet 형식 사용
 - » 스칼라는 DataFrame과 DataSet 모두 사용

카탈리스트 옵티マイ저

- Job의 최적화를 수행하는 엔진




스파크 2.0

- 성능 강화, 구조적 스트리밍, 데이터셋과 데이터프레임 통합 등의 변화



Distribute collection
of JVM objects

Functional Operators (map,
filter, etc.)



Distribute collection
of Row objects

Expression-based operations
and UDFs

Logical plans and optimizer

Fast/efficient internal
representations




Internally rows, externally
JVM objects

Almost the “Best of both
worlds”: type safe + fast

But slower than DF
Not as good for interactive
analysis, especially Python

구조적 스트리밍


- 실시간 연속성 데이터에 대한 처리 지원
- 스트리밍 처리를 단순화하기 위해 배치와 스트리밍을 하나의 API로 통합



지속적 애플리케이션

- 스파크를 기반으로 엔드 투 엔드 애플리케이션 개발 가능

Example



스파크 실행 환경 구축

spark-install, zeppelin-install 파일 참고